

Easy Dataset 数据集创建流程

概述

Easy Dataset 是一个专为大型语言模型（LLM）微调数据集创建而设计的应用程序。本文档详细介绍从 PDF 文件中提取文本块、生成问答对、验证数据集的完整流程。

创建项目 → 配置模型 → 配置分块参数 → 上传PDF → 生成问题 → 生成答案 → 验证数据集 → 导出数据集

第一步：创建项目

在主页创建新项目，填写项目名称和描述。

第二步：配置模型

在模型设置页面，添加并配置至少一个模型提供商，执行健康检查确认模型可用。

支持的模型提供商

提供商 ID	名称
ollama	Ollama（本地部署）
openai	OpenAI
siliconcloud	硅基流动
deepseek	DeepSeek
302ai	302.AI
zhipu	智谱AI
Doubao	火山引擎
groq	Groq
grok	Grok
OpenRouter	OpenRouter
alibailian	阿里云百炼
minimax	MiniMax

模型健康检查

系统提供模型端点健康检查功能，用于验证模型配置是否正确可用：

1. 系统向模型的 API 端点发送测试请求
2. 验证端点是否可达、API 密钥是否有效
3. 获取模型列表，确认当前选择的模型是否存在于列表中
4. 返回检查结果，显示健康或异常状态及详细信息

状态	图标颜色	含义
未检测	灰色	尚未执行健康检查
检测中	灰色	正在检测端点连通性
健康	绿色	端点可达，模型可用
异常	红色	端点不可达或配置错误

第三步：配置分块参数

在文本分割设置页面，根据文档特点选择合适的分块方法并调整参数。

系统提供 **5 种** 文本分块方法：

3.1 智能 Markdown 分块（默认方法）

当未显式指定分块类型时，系统自动使用此方法。

基于 Markdown 文档的标题层级结构进行智能分块。处理过程：扫描全文提取标题构建大纲 → 按标题边界拆分段落 → 合并短段落、拆分超长段落。该方法会自动为每个块生成摘要。

参数名	说明	默认值	建议范围
<code>textSplitMinLength</code>	块的最小字符数，低于此值会与相邻段落合并	1500	500 - 3000
<code>textSplitMaxLength</code>	块的最大字符数，超过此值会被进一步拆分	2000	1000 - 5000

3.2 字符分块（`text`）

按指定分隔符切分文本，相邻块可合并以减少碎片。不理解文档结构，适合简单文本。

参数名	说明	默认值	建议范围
<code>chunkSize</code>	每个块的目标字符数	1500	500 - 5000
<code>chunkOverlap</code>	相邻块重叠的字符数	200	0 - 500
<code>separator</code>	分隔符	<code>\n\n</code>	<code>\n</code> 、 <code>。</code> 等

3.3 Token 分块 (token)

按 Token 数量分块，生成的每个块消耗的 Token 数量精确可控，直接对应 LLM 的输入 Token 消耗。

参数名	说明	默认值	建议范围
chunkSize	每个块的目标 Token 数量	1500	500 - 8000
chunkoverlap	相邻块重叠的 Token 数量	200	0 - 500

3.4 递归分块 (recursive)

使用多级分隔符列表进行递归分割：先尝试第一优先级分隔符，若块仍超长则使用下一优先级分隔符继续分割。

参数名	说明	默认值	建议范围
chunkSize	每个块的目标字符数	1500	500 - 5000
chunkoverlap	相邻块重叠的字符数	200	0 - 500
separators	多级分隔符列表，按优先级从高到低排列	['\ ', '##', '>', '-']	见下文

分隔符列表设计：

列表应从"最强边界"到"最弱边界"排列：

- **Markdown 文档：** ['---', '##', '###', '\\n\\n', '\\n', '。', '.']
- **一般文本：** ['\\n\\n', '\\n', '。', '!', '?', '!', '?']
- **混合内容：** ['|', '##', '>', '-', '\\n\\n', '\\n']

3.5 自定义分块 (custom)

用户指定任意字符串作为分隔符，严格按分隔符切割，不做合并或再分割。

参数名	说明	默认值	建议范围
customSeparator	自定义分隔符	---	任意字符串

分块方法选择指南

智能 Markdown 分块是处理 Markdown 文档的首选方法。它能感知文档的标题层级结构，自动识别章节边界，并为每个块生成摘要。这是唯一支持自动生成摘要的方法，适合需要保留文档语义结构的场景。

字符分块是最简单的方法，按指定分隔符（如双换行）切分文本。它不理解文档结构，纯粹基于字符匹配，适合结构简单的纯文本或已预处理过的文本。

Token 分块按 Token 数量而非字符数量分块，每个块消耗的 Token 数量精确可控。当需要精确匹配 LLM 的上下文窗口限制时，这是最佳选择。

递归分块使用多级分隔符列表逐级分割，优先在更重要的边界处分割。它比字符分块更智能，但效果取决于分隔符列表的设计，适合结构化文档。

自定义分块允许用户指定任意分隔符，严格按分隔符切割。适合用户明确知道文档分隔模式的场景，如用特定标记分隔的多篇文章。

第四步：上传 PDF

进入项目页面，上传一个或多个 PDF 文件。系统会自动调用转换策略将 PDF 转为 Markdown，并使用已配置的分块参数进行文本分割。

系统提供 **4 种** PDF 处理策略，适用于不同类型的 PDF 文档：

4.1 默认转换 (default)

直接使用 PDF 解析库提取文本内容，转换为 Markdown 格式。

原理：解析 PDF 的文本层和基本布局，提取文字内容并转换为 Markdown 格式。

适用场景：常规文档型 PDF，文字清晰、布局简单的文档。

特点：

- 无需额外配置，开箱即用
- 转换速度快
- 依赖 PDF 内嵌的文字层，扫描件或图片型 PDF 效果差
- 对复杂排版（多栏、表格）支持有限

4.2 MinerU 云端解析 (mineru)

调用 MinerU 云端服务进行 PDF 解析，支持公式识别、表格提取和 OCR。

原理：将 PDF 上传至 MinerU 云端服务，使用其文档布局分析模型和 VLM 引擎进行深度解析，返回结构化的 Markdown 内容。

适用场景：复杂排版文档，如学术论文、技术报告、多栏报纸等。

特点：

- 支持公式识别
- 支持表格提取
- 支持 OCR 识别
- 解析质量高，能保留文档结构
- 需要配置 MinerU Token
- 需要网络连接，处理时间较长

外部依赖：MinerU 云服务（需要在 MinerU 官网注册并获取 Token）

4.3 MinerU 本地解析 (mineru-local)

调用本地部署的 MinerU 服务进行 PDF 解析，功能与云端版相同，但数据不离开本地。

原理：将 PDF 发送至本地部署的 MinerU 服务，使用本地 VLM 引擎进行解析。

适用场景：对数据隐私有要求，或需要离线处理的场景。

特点：

- 功能与云端版一致
- 数据完全本地处理，不上传至云端
- 需要本地部署 MinerU 服务
- 处理速度取决于本地硬件性能

外部依赖： 本地 MinerU 服务（需要预先部署）

4.4 视觉模型转换（vision）

使用视觉大模型（如 Minimax、Kimi）逐页识别 PDF 内容，将其转换为 Markdown。

原理： 将 PDF 每页渲染为图片，发送给视觉大模型，由模型识别页面内容并生成 Markdown 文本。系统会先进行页面转文本，然后对生成的标题进行优化重组。

适用场景： 包含大量图片、图表、扫描件等视觉内容丰富的 PDF。

特点：

- 能识别图片、图表等非文字内容
- 理解复杂排版和视觉布局
- 转换质量最高，语义理解能力强
- 需要配置视觉模型
- 处理速度较慢，按页调用 API
- Token 消耗较大，成本较高

外部依赖： 支持视觉输入的 LLM 提供商（需要配置视觉模型）

处理策略选择指南

策略	解析质量	处理速度	成本	配置要求
默认转换	一般	最快	免费	无
MinerU 云端	高	中等	中等	MinerU Token
MinerU 本地	高	较慢	免费	本地服务
视觉模型	最高	最慢	较高	视觉模型

第五步：生成问题

选择需要生成问题的文本块，配置使用的 AI 模型和语言参数，启动问题生成任务。

参数	说明
并发数	同时处理的文本块数量（默认 2）
语言	生成问题的语言（中文/英文）
GA 扩展	是否基于"文体+受众"维度扩展问题多样性
问题数量	每个文本块生成的问题个数

每 1000 字建议生成 3-5 个问题，开启 GA 扩展可提升问题多样性，优先选择高质量模型以获得更好的问题。

问题质量约束

- 所有问题必须严格基于文本内容，不得添加外部信息
- 问题之间不得重复，需覆盖文本的不同侧面
- 禁止生成与文档元信息（作者、章节等）相关的问题
- 问题表述需自然流畅，不得包含"文献中提到"等引用性表述

第六步：生成答案

选择需要生成答案的问题（或全选），配置 AI 模型，启动答案生成任务。

参数	说明
并发数	同时处理的问题数量（默认 3）
语言	生成答案的语言
模型配置	使用的模型提供商、模型名称、API 密钥等

复杂推理问题建议使用能力强的模型，简单事实性问题可使用经济型模型。启用思维链可提升答案的可解释性和质量。

答案生成流程

1. 获取待处理问题及其关联的文本块内容
2. 将文本块和问题嵌入答案生成提示词模板
3. 若问题关联了 GA pair（文体+受众），使用增强版提示词
4. 调用 LLM 获取答案和思维链（COT）
5. 若模型未返回思维链，系统自动基于问题、文本和答案合成人造思维链
6. 创建数据集条目，将问题标记为"已生成答案"

答案质量约束

- 答案必须完全基于提供的文本内容，不得虚构信息
- 答案必须准确回答问题的核心要求
- 答案需充分详细，包含所有必要信息
- 答案中不得出现"参考/依据/文献中提到"等引用性表述

第七步：验证数据集

选择数据集条目，启动 AI 评估任务，查看评分和评语，根据评分筛选或重新生成质量不达标的条目。

评估维度

维度	权重	评估内容
问题质量	25%	问题表述是否清晰、难度是否适中、语法是否正确
答案质量	35%	答案是否准确完整、逻辑是否清晰、是否基于原文
文本相关性	25%	问题和答案与原始文本的关联程度
整体一致性	15%	问答之间是否形成逻辑闭环、是否适合模型训练

评分标准

分数	含义
5 分	近乎完美，可直接用于模型训练
4 分	高质量，适合模型训练
3 分	中等质量，需轻微调整后使用
2 分	存在明显问题，需修改后才能使用
1 分	质量较差，不建议用于训练
0 分	完全不适合训练

建议将 3.5 分作为可用阈值，低于 2 分的条目建议重新生成，评估结果可作为筛选和迭代优化的依据。系统支持批量评估，评估过程中会实时更新进度。

第八步：导出数据集

选择满意的条目，选择导出格式，下载微调训练数据集文件。

支持的导出格式

格式	说明
JSON	通用结构化格式，包含完整元数据
JSONL	每行一条 JSON 记录，适合流式加载
CSV	表格格式，便于在 Excel 中查看编辑
Alpaca	LLaMA 系列模型的微调训练格式
ShareGPT	ChatGPT 风格的对话训练格式

导出内容

字段	说明
id	数据集条目唯一标识符
question	问题内容
answer	答案内容
model	生成答案使用的模型名称
cot	思维链（可选）
questionLabel	问题标签/分类
score	AI 评估分数（若已评估）

附录

任务系统

所有耗时操作均通过异步任务执行，用户可实时查看进度。

任务类型	描述
文件处理	PDF 转 Markdown 及文本分块
问题生成	从文本块生成问题列表
答案生成	为问题生成答案并创建数据集
数据清洗	清洗和优化已有数据
数据蒸馏	从已有数据中提炼新数据
数据评估	对数据集进行质量评估
模型评估	测试模型在评估集上的表现
盲测对比	两个模型的对比测试

任务状态： 0=待处理 / 1=已完成 / 2=失败 / 3=已中断

并发控制： 每种任务类型均可配置并发数（默认 2-3），支持中途取消。

模型评估（盲测对比）

系统支持对比不同模型在同一测试集上的表现：

- 准备测试集：从数据集选择或自动生成评估题目（支持判断题、单选题、多选题、简答题、开放题）
- 配置被测模型和评审模型
- 系统将题目发送给被测模型，收集回答
- 评审模型对每个回答进行评分
- 汇总得分，生成评估报告

用户可为每种题型配置自定义评分锚点（Score Anchors），精确控制评审标准。支持两个模型盲测对比：将相同题目分别发送给模型 A 和模型 B，评审模型在不知道回答来源的情况下评分，最终比较综合得分。

最后更新：2026-07-15